

Deep Learning Avancé & Applications

Interprétabilité, Robustesse & Éthique

Master Bac+5 – Data Analytics & Big Data

Mouaad AGOURRAM

2025–2026

Golden Collar

Interprétabilité (XAI)

Robustesse & Sécurité

Biais & Équité

Éthique & Gouvernance

Synthèse

Interprétabilité (XAI)

Pourquoi l'interprétabilité ?

Le problème de la boîte noire

- Modèles profonds opaques, des millions de paramètres
- Décisions non explicables a priori
- Confiance limitée des utilisateurs

Nécessité de l'explicabilité

- **Réglementaire** : RGPD, AI Act (UE)
- **Médical** : justifier un diagnostic
- **Finance** : expliquer un refus de crédit
- **Debug** : comprendre les erreurs
- **Confiance** : adoption par les utilisateurs

Un modèle performant mais inexplicable est-il vraiment déployable en production ?

Taxonomie des méthodes d'interprétabilité

Famille	Idée	Exemples
Intrinsèque	modèle transparent par construction	arbres, règles, GAM, attention
Post-hoc local	expliquer <i>une</i> prédiction	LIME, SHAP, Grad-CAM
Post-hoc global	comportement <i>global</i> du modèle	feature importance, PDP, TCAV
Mécaniste (2023+)	comprendre les <i>calculs internes</i>	circuits, sparse autoencoders

Deux axes transverses

- **Portée** : locale (une instance) vs globale (le modèle)
- **Accès** : agnostique (boîte noire) vs spécifique (gradients, poids)

Choisir selon le besoin

Audit réglementaire → global ; justifier une décision client → local ; recherche de sûreté sur un LLM → mécaniste.

Méthodes post-hoc : LIME, SHAP, Grad-CAM

LIME

Approxime **localement** le modèle par un modèle linéaire interprétable autour de chaque prédiction.

SHAP (SHapley Additive exPlanations)

Valeurs de Shapley (théorie des jeux) : attribue à chaque feature sa **contribution marginale**. Garanties d'additivité et de cohérence.

Grad-CAM (vision)

Utilise les gradients vers la dernière couche conv pour produire une *heatmap* des régions responsables de la prédiction.

Globales

Feature importance, **PDP** (effet d'une variable), **TCAV** (sensibilité à un concept humain).

Grad-CAM et SHAP en pratique

```
1  # Grad-CAM pour un CNN
2  import tensorflow as tf
3  import numpy as np
4
5  def grad_cam(model, image, layer_name, class_idx):
6      grad_model = tf.keras.Model(
7          [model.inputs], [model.get_layer(layer_name).output, model.output]
8      )
9      with tf.GradientTape() as tape:
10         conv_outputs, predictions = grad_model(image[np.newaxis, ...])
11         loss = predictions[:, class_idx]
12         grads = tape.gradient(loss, conv_outputs)
13         weights = tf.reduce_mean(grads, axis=(1, 2)) # Global Average Pooling
14         cam = tf.nn.relu(tf.reduce_sum(weights * conv_outputs, axis=-1))
15         return cam.numpy()[0]
16
17 # SHAP pour un modele quelconque
18 import shap
19 explainer = shap.DeepExplainer(model, X_train[:100])
20 shap_values = explainer.shap_values(X_test[:10])
21 shap.summary_plot(shap_values, X_test[:10])
```

Attention : une explication n'est pas la vérité


Les explications peuvent être infidèles

Sanity Checks (Adebayo et al., 2018) : certaines saliency maps restent **quasi identiques** même après **randomisation des poids** du modèle ou des labels.

⇒ elles ressemblent à une explication, mais ne reflètent **pas** le calcul réel du modèle : « **illusions d'interprétabilité** ».

Précautions

- Tester la **fidélité** (l'explication change-t-elle si le modèle change ?)
- Croiser plusieurs méthodes
- Se méfier des explications « trop belles »




⇒ explication non fidèle

Comprendre les calculs internes, pas juste les sorties

- **Superposition** : un même neurone encode **plusieurs** concepts $\Rightarrow$ neurones *polysémantiques*, difficiles à lire
- **Sparse Autoencoders (SAE)** : décomposent les activations en **features monosémantiques** (un concept = une direction)
- **Circuits** : sous-graphes de calcul réutilisables

Travaux récents (LLMs)

- **Anthropic** : *attribution graphs* sur Claude 3.5 Haiku (modèle de production)
- **DeepMind** : *Gemma Scope* — SAE jusqu'à 27B paramètres



Limite

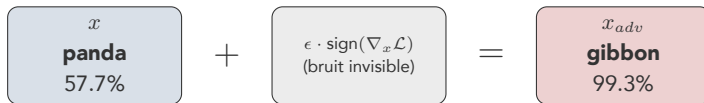
Les SAE dégradent encore les performances ($\sim 10\text{--}40\%$) ; outil de recherche, pas encore une garantie.

Robustesse & Sécurité

Attaques adversariales (vision)

Principe — perturbation imperceptible (Goodfellow et al., 2014)

$$x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(\theta, x, y))$$



Attaques

FGSM (1 étape) · PGD (itératif) · C&W (optimisation) · patches physiques

Défenses

Adversarial training · prétraitement (débruitage) · défenses certifiées · ensembles

Les risques majeurs des applis LLM

1. **Prompt Injection** (LLM01) — risque #1
2. **Sensitive Information Disclosure**
3. **Supply Chain** (modèles/datasets tiers)
4. **Data & Model Poisoning**
5. **Improper Output Handling**
6. **Excessive Agency** (agents trop autonomes)
7. System Prompt Leakage · Vector/Embedding · Misinformation · Unbounded Consumption

Prompt injection — directe vs indirecte

- **Directe** (jailbreak) : l'utilisateur contourne les garde-fous (« ignore tes instructions... »)
- **Indirecte** : instructions cachées dans un document/web/email lu par le LLM (RAG, agents)

Spécificité LLM

Le **même canal** véhicule données **et** instructions ⇒ séparer les deux est intrinsèquement difficile.

Défendre un système LLM

Red-teaming

- Tester l'IA en **attaquant** : jailbreaks, injections, abus d'agent
- Manuel + **automatisé** (générateurs d'attaques)
- Avant ET en continu après déploiement

Guardrails

- Classifieurs d'entrée/sortie (ex. *Prompt Shields*)
- Filtrage PII, modération de contenu
- Limiter l'**agency** : permissions minimales, validation humaine des actions sensibles

Bonnes pratiques agent / RAG

- Traiter le contenu récupéré comme **non fiable**
- **Human-in-the-loop** pour les actions irréversibles
- **Sandboxing** des outils (exécution de code, accès réseau)
- Journaliser et monitorer (observabilité)

La sécurité d'un LLM se joue au niveau du système, pas du seul modèle.

Distribution shift et robustesse en production

Le vrai danger en production

Le modèle rencontre des données **différentes** de l'entraînement :

- **Covariate shift** : la distribution des inputs change
- **Label shift** : la prévalence des classes change
- **Concept drift** : la relation input/output change au fil du temps

Stratégies

- **Monitoring** : surveiller les distributions en production
- **Réentraînement périodique** : mettre à jour le modèle
- **Détection d'OOD** (Out-of-Distribution) : identifier les entrées inhabituelles
- **Estimation d'incertitude** : MC Dropout, ensembles

Biais & Équité

Biais des données

- **Sous-représentation** de certaines populations
- **Biais historique** : les données reflètent des discriminations passées
- **Biais de mesure** : la collecte introduit un biais
- **Biais de labeling** : les annotateurs ont leurs biais

Biais du modèle

- **Amplification** : le modèle amplifie les biais des données
- **Features proxy** : variables corrélées à un attribut sensible
- **Biais d'évaluation** : métriques agrégées masquant les disparités

Gender Shades (Buolamwini & Gebru, 2018)

Analyse faciale commerciale — taux d'erreur de classification du genre :

Sous-groupe	Erreur
Hommes à peau claire	~0.8 %
Femmes à peau foncée	jusqu'à 34.7 %

⇒ une accuracy **globale** élevée cache des disparités énormes.

COMPAS (ProPublica, 2016)

Outil de score de récidive utilisé par des tribunaux US :

- Plus de **faux positifs** pour les accusés noirs
- Plus de **faux négatifs** pour les accusés blancs

La leçon

Toujours **désagréger** les métriques par sous-groupe — la moyenne ment.

Métriques d'équité

- **Demographic Parity** : taux de prédiction positive égal entre groupes
- **Equalized Odds** : TPR et FPR égaux entre groupes
- **Disparate Impact** : ratio des taux de sélection ≥ 0.8 (règle des 4/5)

Stratégies d'atténuation

- **Pré-processing** : rééquilibrer / augmenter les données
- **In-processing** : contrainte d'équité dans le loss
- **Post-processing** : ajuster les seuils par groupe
- **Audit** : tester systématiquement les sous-groupes

Théorème d'impossibilité (Chouldechova, 2017 ; Kleinberg, 2016)

Satisfaire **simultanément** tous les critères d'équité est **mathématiquement impossible** (sauf cas dégénérés). Il faut **choisir** le critère pertinent pour le cas d'usage — c'est une décision **sociotechnique**, pas seulement technique.

Éthique & Gouvernance


Limites techniques

- **Données** : grands volumes annotés
- **Calcul** : coût énergétique et financier
- **Généralisation** : fragile hors distribution
- **Raisonnement** : pas de causalité native
- **Composabilité** : combiner des concepts reste difficile

Enjeux sociétaux

- **Environnement** : empreinte carbone de l'entraînement
- **Vie privée** : données personnelles, deepfakes
- **Emploi** : automatisation de tâches
- **Concentration** : seuls les géants entraînent les plus gros modèles
- **Responsabilité** : qui répond d'une erreur de l'IA ?

Cadre réglementaire : l'AI Act européen



Pyramide de risque de l'AI Act

Une application par paliers


- **Août 2024** : entrée en vigueur
- **Fév. 2025** : interdiction des usages à **risque inacceptable** + obligation de *AI literacy*
- **Août 2025** : obligations pour les modèles **GPAI** (doc. technique, résumé des données, copyright)
- **Août 2026** : gros des obligations **haut risque**

Haut risque ⇒ obligations strictes

Gestion des risques, qualité des données, traçabilité, supervision humaine, robustesse, transparence.

NIST AI RMF (2023) — volontaire

4 fonctions pour gérer le risque IA :



+ *Generative AI Profile* (NIST-AI-600-1, 2024)

ISO/IEC 42001 (2023)

1^{re} norme certifiable de système de management de l'IA — couvre tout le cycle de vie (conception → exploitation).

Documentation & contrôle

- **Model cards** : capacités et limites du modèle
- **Datasheets for datasets** : provenance des données
- **Audit régulier** : biais, performance, robustesse
- **Human-in-the-loop** sur les décisions critiques

Synthèse

TD : Interprétabilité

- Grad-CAM + SHAP sur un CNN CIFAR-10
- Repérer des **raccourcis** (corrélations fallacieuses)
- **Sanity check** : l'explication change-t-elle si on randomise les poids ?

TP : Robustesse & biais

- Générer des exemples **FGSM**, mesurer la chute de perf
- **Adversarial training** et gain de robustesse
- **Audit de biais** : métriques d'équité par sous-groupe

TP bonus : Sécurité LLM

- **Red-team** un chatbot RAG : tenter une **prompt injection** directe (jailbreak) puis **indirecte** (instruction cachée dans un document)
- Ajouter un **guardrail** (classifieur d'entrée) et re-tester
- Rédiger une **model card** courte

Ce qu'on doit retenir de cette séance

Interprétabilité

- Post-hoc (LIME/SHAP/Grad-CAM) utile mais **pas toujours fidèle**
- L'**interprétabilité mécaniste** (SAE, circuits) ouvre la boîte noire des LLM

Robustesse & sécurité

- Adversarial (FGSM/PGD) + **sécurité LLM** (OWASP : prompt injection, agents)
- Sécurité au niveau **système** : red-teaming, guardrails, HITL

Biais & équité

Désagréger les métriques ; l'équité **parfaite** est impossible (Chouldechova) ⇒ choix sociotechnique.

Gouvernance

- **AI Act** (par paliers), **NIST AI RMF**, **ISO 42001**
- Model cards, datasheets, audit, human-in-the-loop

Séance suivante : Étude de cas & mini-projet

Questions ?